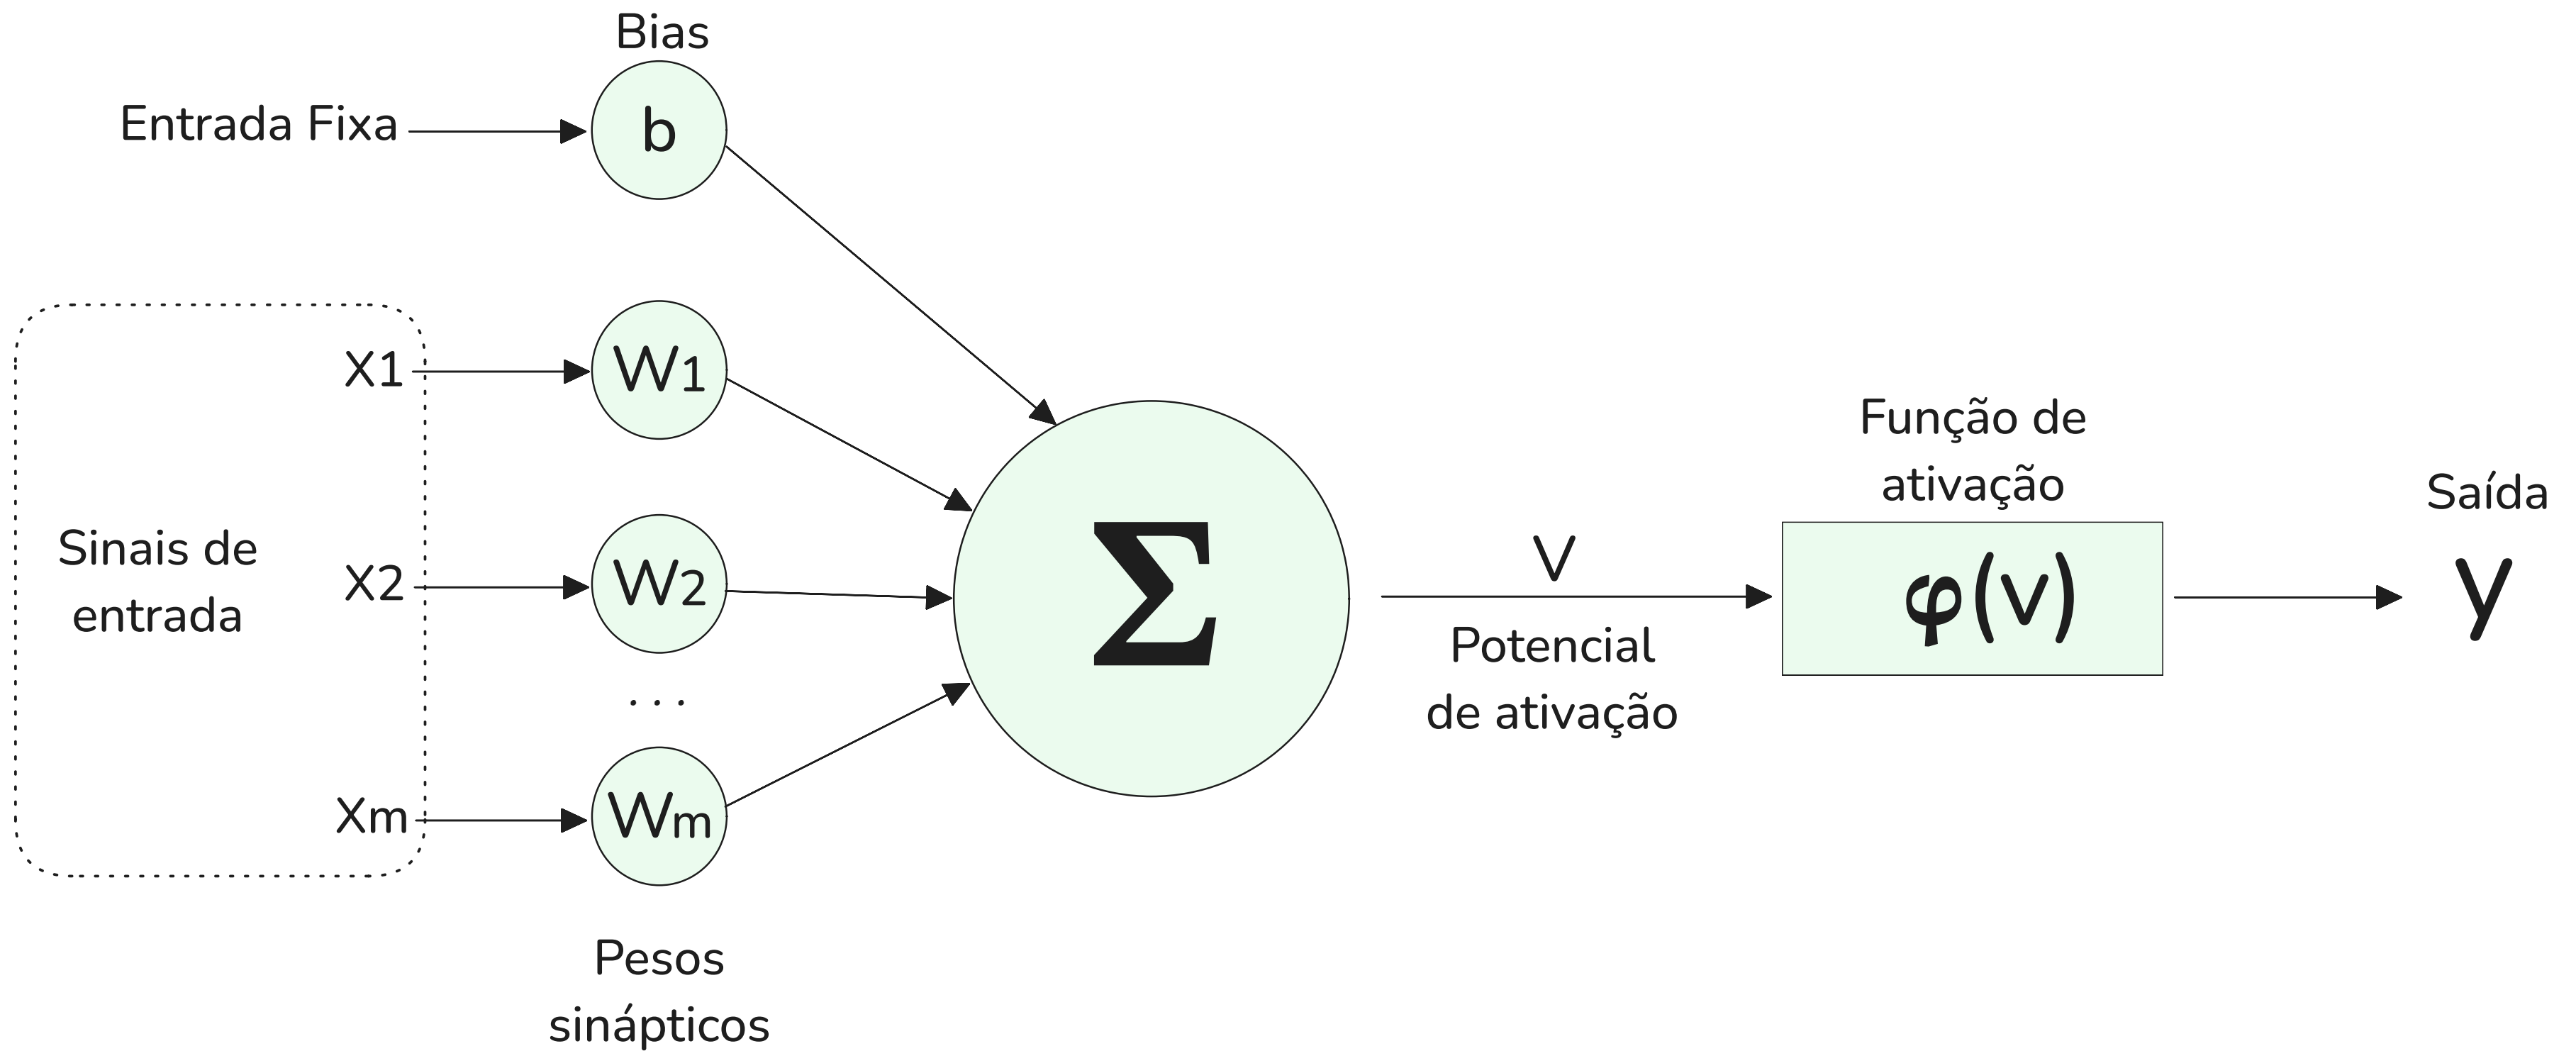


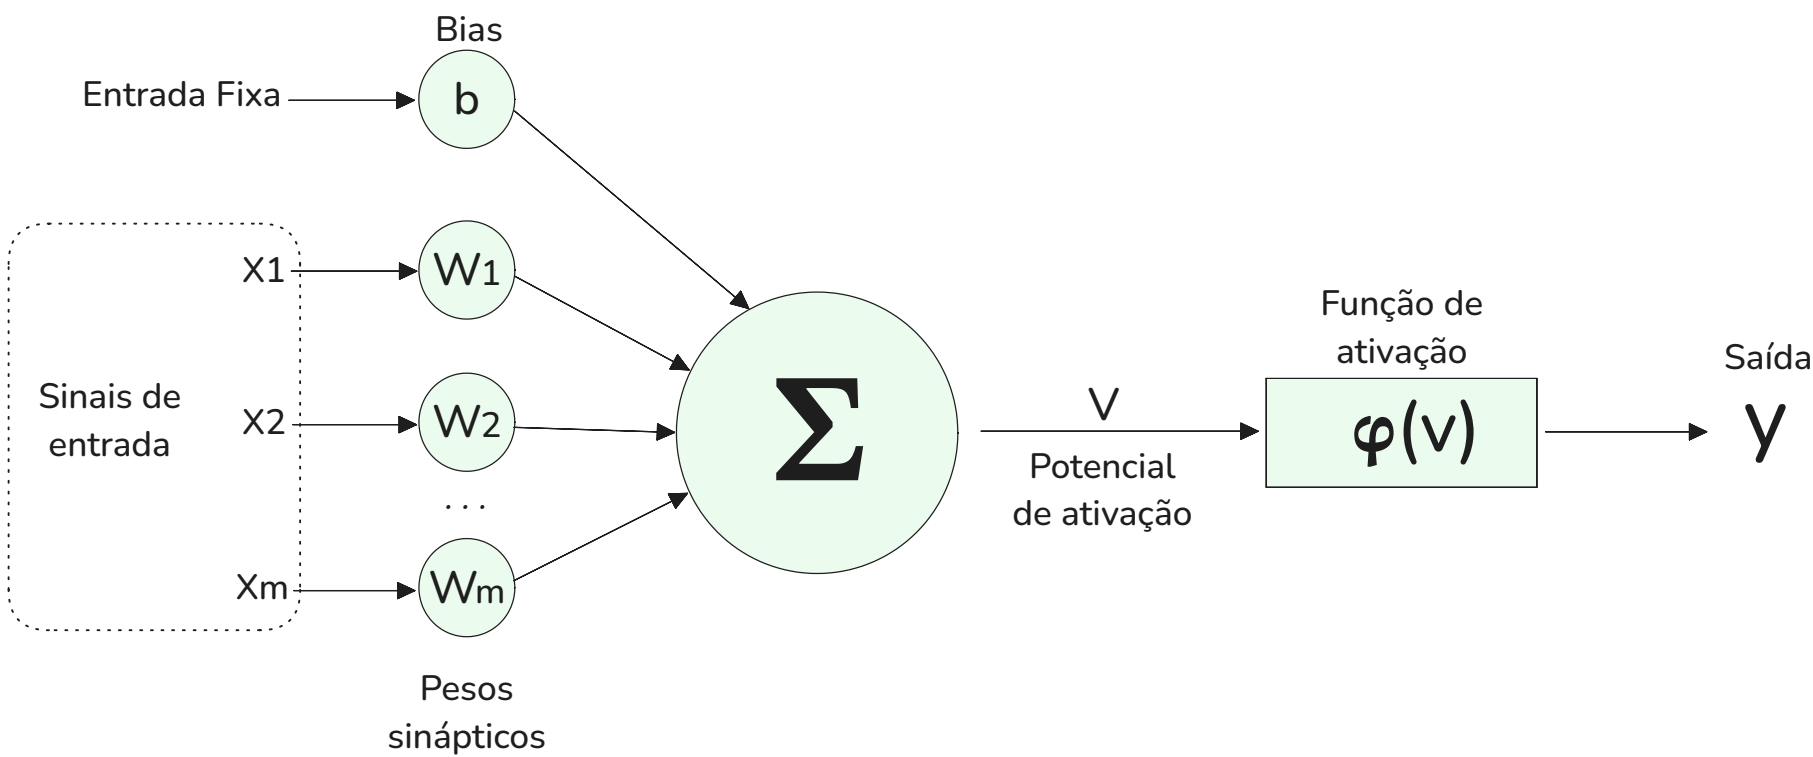
Perceptron de Rosenblatt (1958)



```
1 # Função de ativação (função degrau)
2 def step_function(x):
3     return np.where(x >= 0, 1, 0)
```

```
1 # Classe do Perceptron
2 class Perceptron:
3     def __init__(self, input_size, learning_rate=1.0, epochs=10):
4         self.weights = np.zeros(input_size + 1) # +1 para o bias
5         self.learning_rate = learning_rate
6         self.epochs = epochs
7
8     def predict(self, x):
9         x_with_bias = np.insert(x, 0, 1) # Adiciona o bias
10        weighted_sum = np.dot(self.weights, x_with_bias)
11        return step_function(weighted_sum)
12
13    def fit(self, X, y):
14        for epoch in range(self.epochs):
15            for xi, yi in zip(X, y):
16                xi_with_bias = np.insert(xi, 0, 1) # Adiciona o bias
17                output = self.predict(xi)
18                error = yi - output
19                self.weights += self.learning_rate * error * xi_with_bias
```

Perceptron de Rosenblatt (1958)



```
1 # Função de ativação (função degrau)
2 def step_function(x):
3     return np.where(x >= 0, 1, 0)
```

```
1 # Classe do Perceptron
2 class Perceptron:
3     def __init__(self, input_size, learning_rate=1.0, epochs=10):
4         self.weights = np.zeros(input_size + 1) # +1 para o bias
5         self.learning_rate = learning_rate
6         self.epochs = epochs
7
8     def predict(self, x):
9         x_with_bias = np.insert(x, 0, 1) # Adiciona o bias
10        weighted_sum = np.dot(self.weights, x_with_bias)
11        return step_function(weighted_sum)
12
13    def fit(self, X, y):
14        for epoch in range(self.epochs):
15            for xi, yi in zip(X, y):
16                xi_with_bias = np.insert(xi, 0, 1) # Adiciona o bias
17                output = self.predict(xi)
18                error = yi - output
19                self.weights += self.learning_rate * error * xi_with_bias
```

Correspondência entre Diagrama de Rosenblatt e Código Python

Elemento da Figura	Correspondente no Código
X_1, X_2, \dots, X_m (Sinais de entrada)	<code>x</code> (cada vetor de entrada do array <code>X</code> no código, por exemplo <code>[1, 0]</code>)
W_1, W_2, \dots, W_m (Pesos sinápticos)	<code>self.weights[1:]</code> (os pesos associados às entradas)
b (Bias / Entrada Fixa)	<code>self.weights[0]</code> (peso do bias; o valor constante 1 é inserido via <code>np.insert(x, 0, 1)</code>)
Σ (Soma ponderada)	<code>self.weights[0]</code> (peso do bias; o valor constante 1 é inserido via <code>np.insert(x, 0, 1)</code>)
v (Potencial de ativação)	<code>weighted_sum</code> (a soma ponderada entre pesos e entradas, incluindo o bias)
$\phi(v)$ (Função de ativação)	<code>step_function(x)</code> – a função degrau binária (0 ou 1)
y (Saída do neurônio)	<code>output</code> (retorno da função <code>predict(x)</code>)

