

# Tópicos Avançados em IA

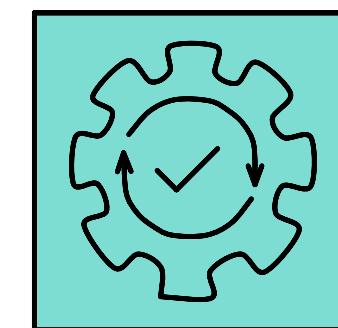
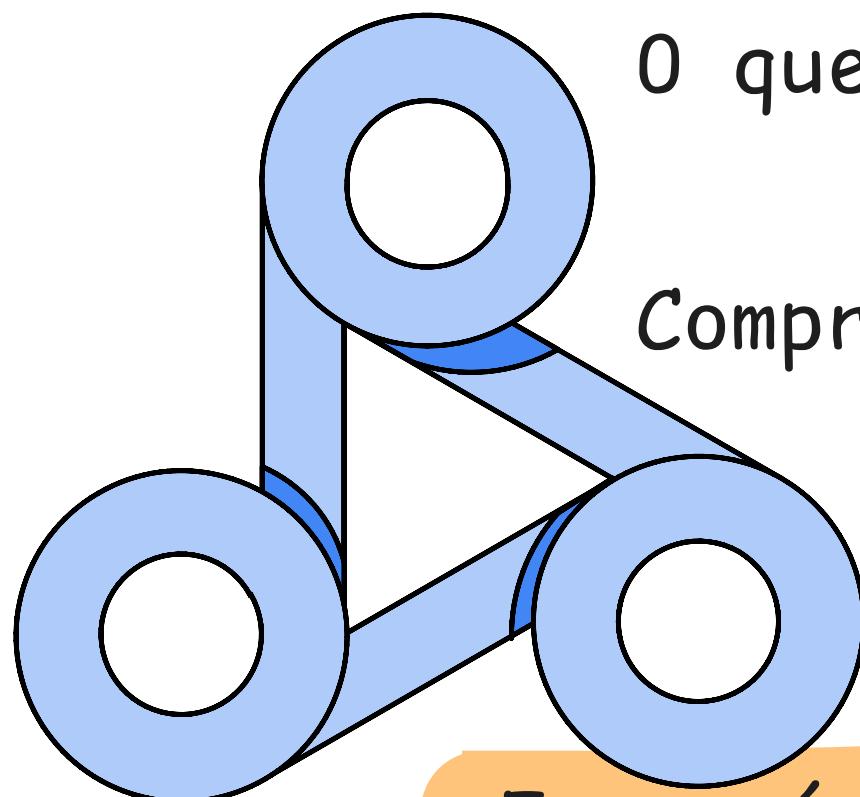
Ambiente Profissional de IA

# De modelos a sistemas

Como a IA é construída na prática

O que muda quando a IA sai do laboratório e entra em produção

Compreender IA como sistema, não como algoritmo

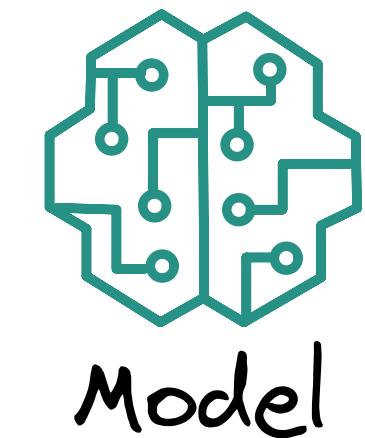


Esse código funcionaria daqui a seis meses, em outra máquina?

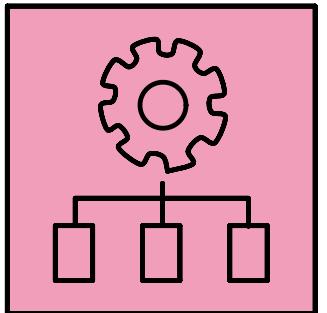
# A visão tradicional (inicial) de IA

Machine Learning como modelo treinado

Foco no algoritmo e no treino



Avaliação pontual em dataset de teste



Código experimental e descartável

Limitações dessa abordagem em contextos reais

Se o modelo obteve boa acurácia no teste, o problema está resolvido?

# O problema da visão inicial

Por que modelos “bons” falham no mundo real

Resultados não reproduzíveis

Dificuldade de manutenção

Falta de rastreabilidade

Desconexão entre código e uso real

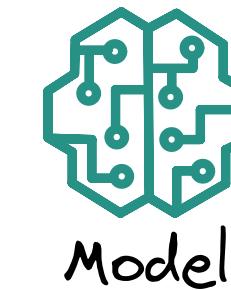


Quando um sistema de IA “falha”, o problema é sempre o algoritmo?

# A mudança de paradigma

Machine Learning como sistema

Modelo é apenas um componente



Sistema envolve dados, código, métricas e decisões

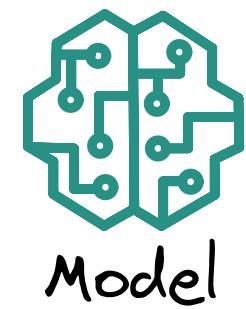
Visão defendida por Chip Huyen

IA como engenharia aplicada

# O que é um sistema de Machine Learning

## Componentes essenciais de um sistema de ML

Dados



Modelo

Integração com outros sistemas

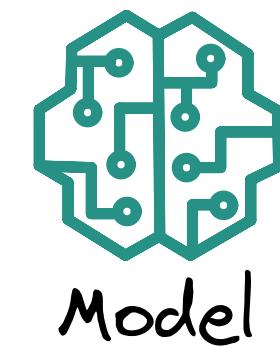
Evolução ao longo do tempo

Processo de treinamento (experiments)

Métricas

# Código experimental x sistema de IA

Script isolado não é sistema



Código experimental: rápido, local, descartável

Sistema de IA: organizado, reproduzível, evolutivo

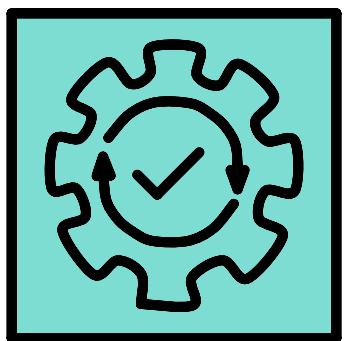
Importância da estrutura desde o início

Se eu sair do projeto, ele continua existindo?

# O papel do ambiente

Ambiente de desenvolvimento não é detalhe

Reprodutibilidade como requisito



Problemas sem ambiente controlado

Conceito de ambiente virtual

Ambiente como parte do sistema

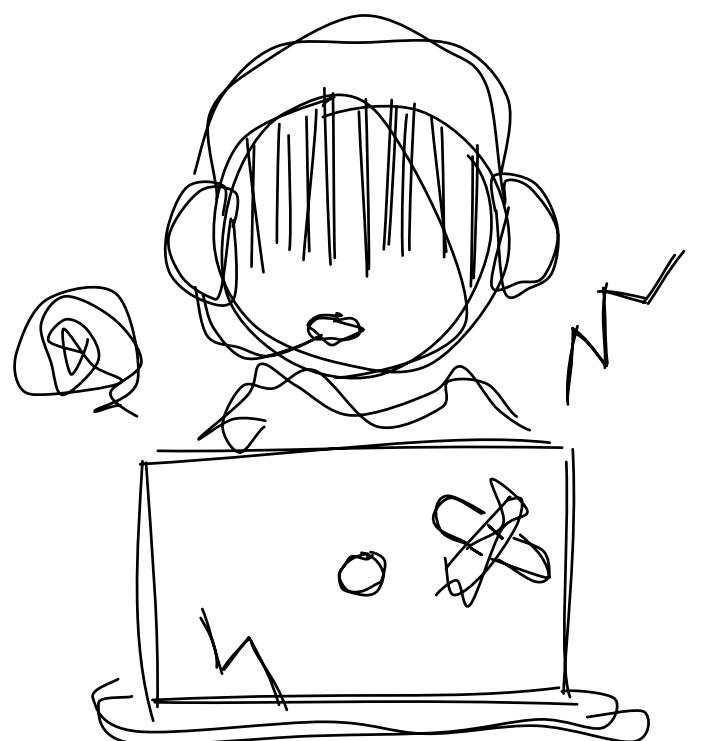
# Organização de projetos de IA

Projetos de IA precisam crescer sem virar caos

Separação entre dados, código e resultados

Experimentos como primeira classe

Importância da estrutura desde o início



# Experimento

Experimento é a unidade básica de trabalho

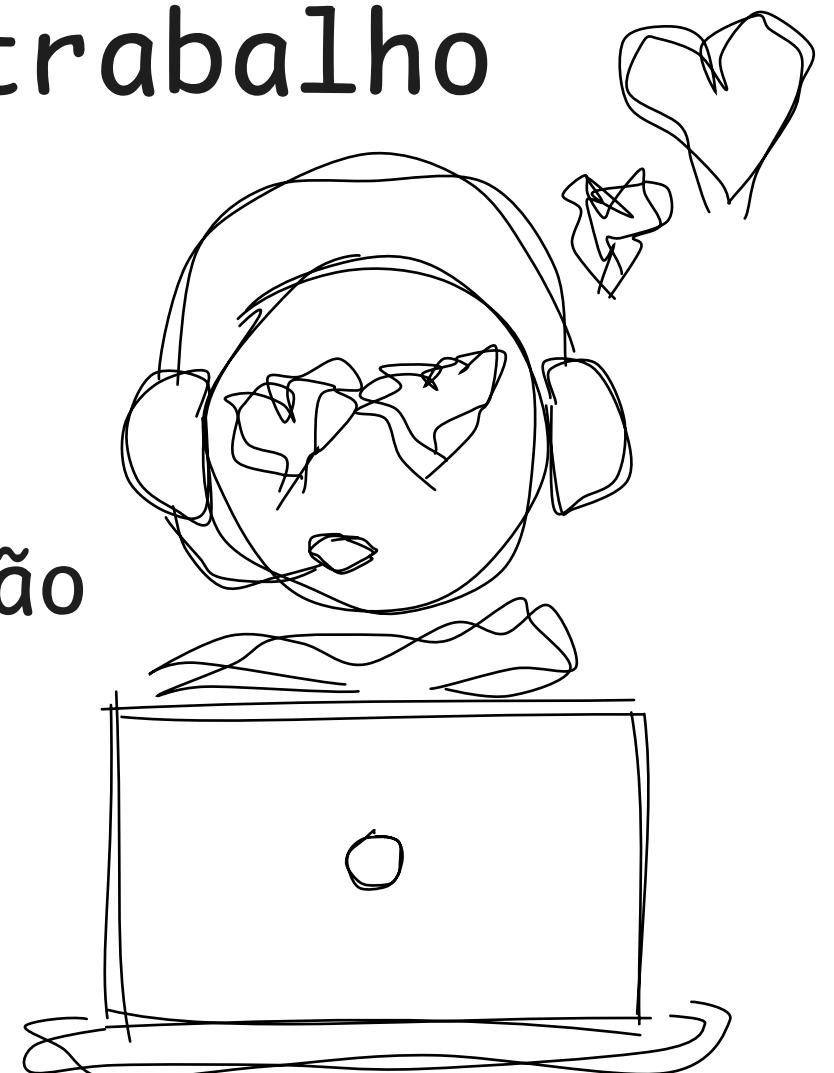
O que caracteriza um experimento

Relação entre dados, parâmetros e execução

Experimento ≠ modelo

Cada execução gera conhecimento

Sem registro, um experimento realmente aconteceu?



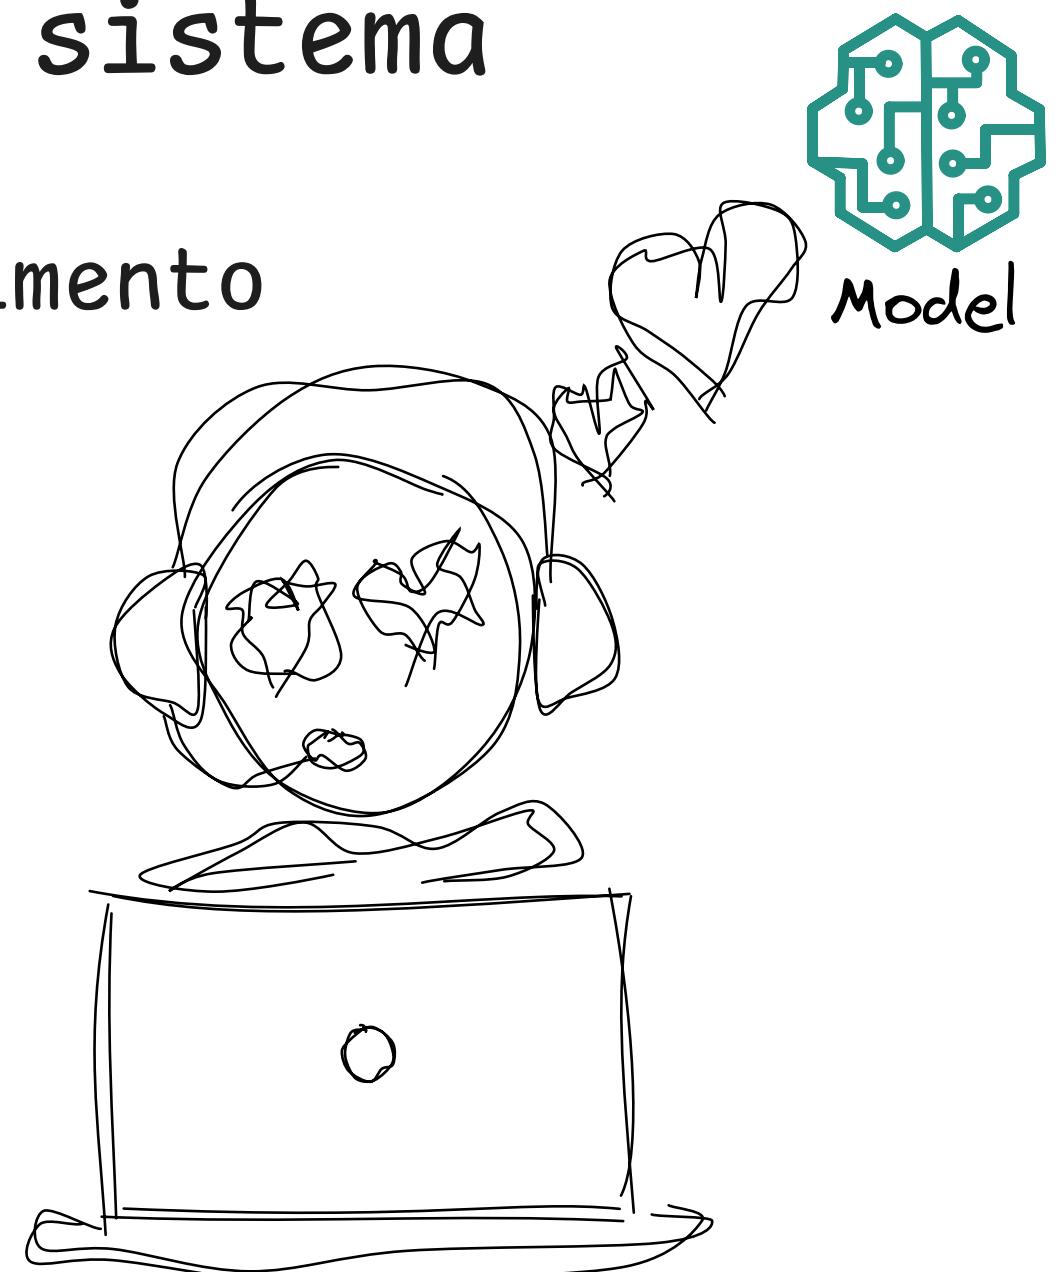
# Modelo

O modelo é um artefato, não o sistema

Modelo como resultado de um experimento

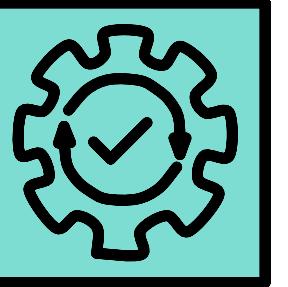
Importância de salvar e versionar

Modelo sem contexto perde valor



# Métrica

Métrica orienta decisões, não apenas resultados



Métrica como critério de escolha

Métrica como instrumento de decisão

Relação entre métrica e objetivo do sistema

Uma métrica alta sempre significa um bom sistema?

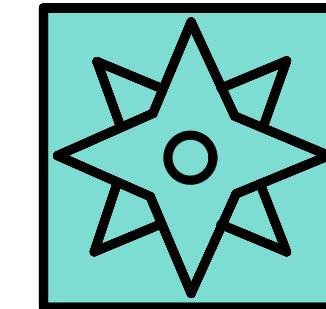


# Processo iterativo

Sistemas de ML evoluem continuamente

Ajustes sucessivos

Aprendizado a partir dos experimentos



Decisões orientadas por métricas

Iteração como característica central

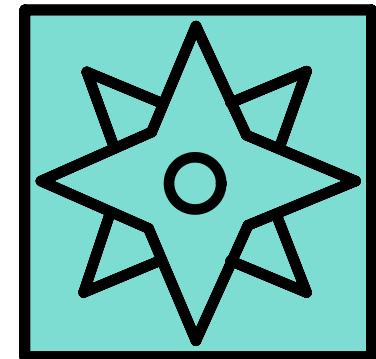
# Versionamento além do código

Versionar código é necessário, mas insuficiente

Código, dados, modelos e resultados evoluem

Rastreabilidade como necessidade

Introdução conceitual ao MLOps



Se o modelo mudou, como você sabe o que mudou?

# Encerramento

De aprendiz a profissional de IA

Aprendiz: foco no modelo

Profissional: foco no sistema

Introdução conceitual ao MLOps

