



Framework para DL

Pesquisa e Indústria

Destques: tensor, GPU, autograd



`torchvision` (imagens)

`torchrec` (recomendações)

`torchao` (eficiência)

`torchft` (fine-tuning)

`executorch` (edge)

`PyTorch/XLA` (TPUs)

```
device = torch.device("cuda")
```

selecionar o dispositivo  
para processamento

```
model = nn.Sequential(  
    nn.Linear(n_in, n_hidden),  
    nn.ReLU(),  
    nn.Dropout(dropout),  
    nn.Linear(n_hidden, n_out)  
)
```

Especificação da  
Arquitetura da  
Rede Neural

## Backpropagation



```
optimizer.zero_grad()      # limpa gradientes anteriores  
loss.backward()            # autograd calcula derivadas  
optimizer.step()           # aplica atualização nos pesos
```

```

1 # Função de treino minimalista
2 def train(X, y, n_hidden=8, lr=0.1, epochs=100, verbose=False):
3     # Tensores
4     X_t = torch.tensor(X, dtype=torch.float32, device=device)
5     y_t = torch.tensor(y.reshape(-1,1), dtype=torch.float32, device=device)
6
7     model = make_mlp(X_t.shape[1], n_hidden, n_out=1)
8
9     criterion = nn.BCEWithLogitsLoss()          # Loss binária
10    optimizer = torch.optim.SGD(model.parameters(), lr=lr) # SGD puro
11
12    losses = []
13    for ep in range(epochs):
14        optimizer.zero_grad()
15        logits = model(X_t)
16        loss = criterion(logits, y_t)
17        loss.backward()
18        optimizer.step()
19        losses.append(loss.item())
20
21        if verbose and (ep % max(1, epochs//10) == 0):
22            print(f"época {ep:4d} | loss={loss.item():.6f}")
23
24    return model, losses

```

Função de  
treinamento

```

1 # MLP simples em PyTorch (1 camada oculta)
2 def make_mlp(n_in, n_hidden, n_out=1, dropout=0.0):
3     return nn.Sequential(
4         nn.Linear(n_in, n_hidden),
5         nn.ReLU(),
6         nn.Dropout(dropout),
7         nn.Linear(n_hidden, n_out) # saída = logit (sem sigmoid aqui)
8     ).to(device)

```