


Evolução das Arquiteturas para Processamento de Sequências Variáveis





O mecanismo de atenção

visão intuitiva

- Query (Q) — o que estou buscando;
- Key (K) — como posso ser encontrado;
- Value (V) — o que tenho a oferecer.



$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$




O mecanismo de atenção do Transformer calcula quanto cada token da entrada deve influenciar os demais, medindo similaridade entre vetores query, key e value.

O mecanismo de múltiplas cabeças de atenção

visão intuitiva









Atenção e normalização conduzem todo o fluxo de informação

O fluxo também depende de embeddings, conexões residuais e feed-forward

O legado dos Transformers para IA Moderna

- BERT — compreensão de linguagem.
- GPT — geração de texto.
- T5 — aprendizado multitarefa.
- ViT — atenção em visão computacional.



O Transformer foi o mecanismo habilitador da era dos modelos fundacionais, mas o desempenho atual emerge da **integração** entre arquitetura, **escala**, **dados**, **adaptação** e **infraestrutura**.

Transformers hoje é fundamento

Não destino final

Base

- tokens
- embeddings
- atenção

representação contextual

Escala

- dados
- GPUs/TPUs
- pré-treinamento

capacidade emergente

Adaptação

- fine-tuning
- RAG
- agentes

especialização prática

Limites

- alto custo
- alucinação
- contexto finito

não é inteligência geral




O principal gargalo dos transformers modernos

Self-attention cresce em custo com o tamanho da sequência

Abordagens modernas:

- long-context
- atenção eficiente (flash attention)
- KV cache
- Sparse attention
- compressão de contexto
- arquiteturas híbridas



[arXiv:2507.19595v1](https://arxiv.org/abs/2507.19595v1)