

PRÁTICA DE ENGENHARIA DE ML COM MLP

1

ETAPA 1 – MODELO CONCEITUAL DO CICLO COMPLETO DE ML

Diagrama do pipeline:

```
Dataset
↓
Pré-processamento
↓
Divisão (train / validation / test)
↓
Arquitetura da MLP
↓
Treinamento
↓
Avaliação
↓
Diagnóstico
↓
Salvamento do modelo
```

2

ETAPA 2 – GERAÇÃO DO CÓDIGO

Crie um projeto Jupyter Notebook e solicitem à IA de sua preferência algo como:

“Implemente em PyTorch uma MLP para classificar o dataset Iris com treino, validação e avaliação.”

Atenção: não faça correção do código ainda.

3

ETAPA 3 – ANÁLISE CRÍTICA DO CÓDIGO

Você consegue identificar decisões de projeto no código gerado?

4

2. PROBLEMAS E DECISÕES DE DESIGN RELEVANTES EM UMA MLP

Para cada etapa do pipeline, quais são os problemas de design mais comuns?

5

A. PROBLEMAS NA PREPARAÇÃO DOS DADOS

6

1. ESCALA DAS VARIÁVEIS

Problema: MLPs são sensíveis à escala dos atributos.

Exemplo:

```
idade: 0-100  
salário: 0-100000
```

Solução:

- StandardScaler
- MinMaxScaler

O dataset foi normalizado? Qual impacto isso tem no treinamento?

7

2. CODIFICAÇÃO DE VARIÁVEIS CATEGÓRICAS

Problema: Redes neurais não lidam diretamente com categorias.

Soluções:

- One-hot encoding
- Embeddings

Como as classes foram representadas?

8

3. BALANCEAMENTO DE CLASSES

Problema: Datasets desbalanceados levam a modelos enviesados.

Exemplo:

```
classe A: 90%  
classe B: 10%
```

Soluções:

- undersampling
- oversampling
- weighted loss

A distribuição das classes foi analisada?

9

B. PROBLEMAS NA DIVISÃO DO DATASET

10

4. ESTRATÉGIA DE PARTICIONAMENTO

Possibilidades:

- train / test
- train / validation / test
- cross validation

Como o modelo evita overfitting sem validação?

11

5. DATA LEAKAGE

Problema: Informação do conjunto de teste vaza para o treino.

Exemplo comum:

`normalização` feita antes da `divisão`

O pipeline evita leakage?

12

C. PROBLEMAS NA ARQUITETURA DA MLP

Aqui começa a engenharia da rede neural.

13

6. NÚMERO DE CAMADAS

Problema:

Rede rasa → underfitting

Rede profunda → overfitting

Por que escolher 1 ou 2 hidden layers?

Observação: Para datasets pequenos (Iris):

- 1 ou 2 camadas são suficientes.

14

7. NÚMERO DE NEURÔNIOS POR CAMADA

Problema: Poucos neurônios → baixa capacidade

Muitos neurônios → overfitting

Heurísticas comuns:

```
hidden ≈ média(input, output)
```

Existe justificativa para o número escolhido?

15

8. FUNÇÃO DE ATIVAÇÃO

- ReLU
- Tanh
- Sigmoid
- LeakyReLU

Problemas associados:

- saturação
- gradiente desaparecendo

Por que ReLU é frequentemente utilizada?

16

9. FUNÇÃO DE SAÍDA

Depende da tarefa.

Classificação binária:

Sigmoid

Classificação multiclasse:

Softmax

A função de saída é compatível com o problema?

D. PROBLEMAS NO TREINAMENTO

10. FUNÇÃO DE PERDA

Escolha depende da tarefa.

Classificação:

- CrossEntropyLoss
- BCEWithLogitsLoss

A função de perda corresponde ao tipo de problema?

11. OTIMIZADOR

Opções comuns:

- SGD
- Adam
- RMSProp

Por que Adam é frequentemente utilizado?

12. TAXA DE APRENDIZADO

Problema:

learning rate muito alto:

divergência

learning rate muito baixo:

treinamento lento

Como saber se o learning rate está adequado?

21

13. BATCH SIZE

Impacta:

- estabilidade
- velocidade
- generalização

O treinamento é batch, mini-batch ou online?

22

14. NÚMERO DE ÉPOCAS

Problema:

poucas épocas → underfitting

muitas épocas → overfitting

Como decidir quando parar o treino?

23

E. PROBLEMAS DE GENERALIZAÇÃO

24

15. OVERFITTING

Sintoma clássico:

```
train accuracy alta  
test accuracy baixa
```

Soluções:

- regularização L2
- dropout
- early stopping

25

16. UNDERFITTING

Sintoma:

```
train accuracy baixa
```

Soluções:

- rede maior
- mais épocas
- melhor feature engineering

26

F. PROBLEMAS NA AVALIAÇÃO

27

17. MÉTRICA INADEQUADA

Accuracy pode ser enganosa.

Alternativas:

- precision
- recall
- F1-score
- ROC AUC

A métrica escolhida reflete o problema?

28

18. ANÁLISE DE ERRO

Em quais classes o modelo erra mais?

Ferramentas:

- confusion matrix

G. PROBLEMAS DE REPRODUTIBILIDADE

19. SEEDS ALEATÓRIAS

Sem seed:

```
resultados variam
```

Solução:

```
torch.manual_seed()
```

31

20. SALVAMENTO DO MODELO

Boa prática:

```
torch.save(model.state_dict())
```

O experimento é reproduzível?

32

3. EXERCÍCIOS

33

EXERCÍCIO 1 – DIAGNÓSTICO DE OVERFITTING

1. treinar a rede
2. comparar curvas

```
train loss  
validation loss
```

O modelo está overfitting?

34

EXERCÍCIO 2 – ALTERAÇÃO DA ARQUITETURA

Treine três modelos:

```
MLP pequena  
MLP média  
MLP grande
```

Compare desempenho.

35

EXERCÍCIO 3 – MUDANÇA DA FUNÇÃO DE ATIVAÇÃO

Altere e compare:

```
ReLU  
Tanh  
Sigmoid
```

36

EXERCÍCIO 4 – MUDANÇA DO OTIMIZADOR

Altere e compare:

```
SGD  
Adam
```

37

4. O QUE REALMENTE ABORDAMOS

Tópicos experienciados:

- engenharia experimental de ML
- interpretação de modelos
- diagnóstico de treinamento
- reprodutibilidade

Ou seja: **competências que ainda sobrevivem à IA generativa.**

38

5. EVIDÊNCIA DA ATIVIDADE REALIZADA

Produza e entregue um pequeno relatório experimental.

Exemplo:

```
Modelo testado: MLP (4-16-3)
Ativação: ReLU
Otimizador: Adam
Learning rate: 0.001

Resultado:
Accuracy: 96%

Observação:
Ao aumentar o número de neurônios para 64 ocorreu overfitting.
```