

Redes neurais artificiais

4

Não há nada tão equitativamente distribuído no mundo como a inteligência: todos estão convencidos de que têm o suficiente.

René Descartes

Introdução

Você compreendeu o capítulo anterior (conexionismo)? Sem o entendimento pleno dos conceitos lá abordados, não será possível a assimilação do conhecimento repassado neste momento. Com a revisão sobre conexionismo, você entenderá a importância da arquitetura de uma rede neural artificial e compreenderá o mecanismo de uma rede *perceptron* multicamada.

Então, agora que você já assimilou os conceitos básicos sobre os neurônios artificiais, podemos aprofundar um pouco mais nosso conhecimento sobre o paradigma conexionista. Vimos que, inicialmente, no caso das redes neurais do tipo *perceptron*, elas eram construídas com uma única camada, podendo ser até mesmo implementadas com um único neurônio. Isso obviamente tornava a rede bastante limitada para aplicações práticas mais complexas. Neste capítulo, falaremos sobre a estrutura de redes neurais com múltiplas camadas e suas respectivas topologias.

4.1 Arquitetura de redes neurais artificiais (RNA)

Um parâmetro importante na hora do desenvolvimento de uma RNA é a definição de sua arquitetura, uma vez que ela é limitada pelo problema que terá de ser resolvido. Já falamos da limitação das redes de uma única camada (*perceptron*), as quais conseguem resolver apenas problemas linearmente separáveis.


Segundo Haykin (2001), a arquitetura de uma RNA é constituída basicamente de três camadas. Veja quais são:

- **camada de entrada:** responsável pela recepção dos valores de entrada que serão processados pelo resto da rede;
- **camada oculta:** também conhecida como camada intermediária, podendo ser única ou com várias subcamadas em cascata. Essa segunda camada é a responsável pelo processamento efetivo dos dados recebidos da primeira camada;

- **camada de saída:** responsável pela fase final do processamento e apresentação dos resultados.

Observe-as na figura a seguir.

Figura 1 *Arquitetura de uma RNA*



Fonte: adaptado de Araujo (2005, p. 33)

Haykin (2001) afirma ainda que a arquitetura de uma rede neural artificial possui uma estreita vinculação com o tipo de treinamento que será utilizado para o aprendizado da rede, que realizará o ajuste dos pesos dos neurônios de cada uma das suas camadas. Em geral, podemos identificar três classes de arquiteturas diferentes. Vejamos.

- **Rede alimentada adiante com camada única:** rede do tipo alimentada adiante ou acíclica.
- **Rede alimentada diretamente com múltiplas camadas:** possui uma ou mais camadas ocultas.
- **Rede recorrente:** distingue-se da rede neural alimentada adiante por ter ao menos um laço de realimentação. Pode consistir, por exemplo, de uma única camada de neurônios com cada neurônio alimentando seu sinal de saída de volta para as entradas de todos os outros neurônios.

Vamos continuar os estudos do treinamento das redes neurais.

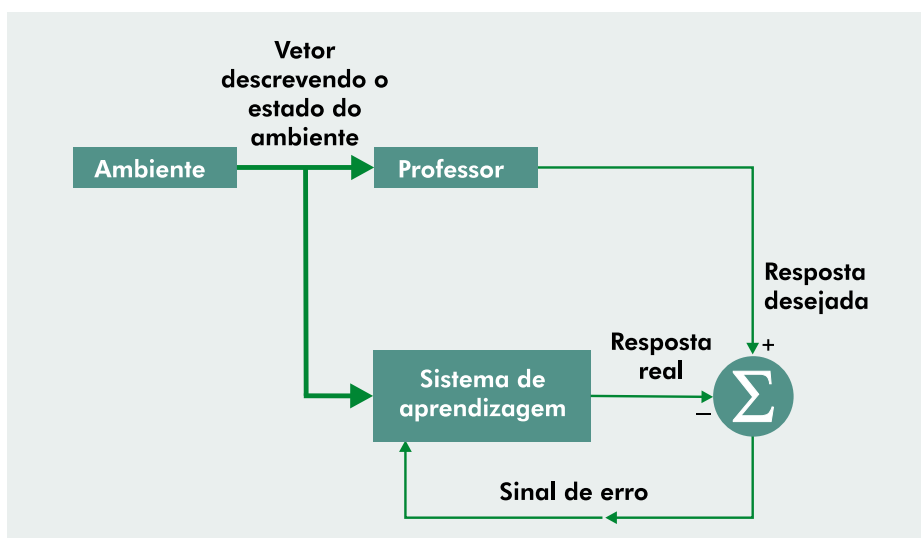
4.2 Treinamento

Como você já deve ter notado, sempre que falamos em redes neurais, falamos no treinamento delas. Isso se deve ao fato de que uma rede neural artificial não tem utilidade se não lhe ensinarmos o que ela deve fazer. Para esse treinamento, dispomos de três métodos de aprendizagem (HAYKIN, 2001):

- supervisionada
- por reforço e
- não supervisionada

Na modalidade de **aprendizagem supervisionada**, são apresentadas à rede as entradas com as respectivas saídas que desejamos que a rede aprenda. Dessa forma, a rede inicialmente calcula a saída que ela teria para aquele conjunto de dados de entrada e, uma vez que ela sabe quais seriam as saídas esperadas, pode verificar o erro que está cometendo, ajustando assim seus pesos proporcionalmente ao valor do erro cometido. Caso a diferença entre a saída calculada e a saída desejada seja nula, não haverá variação dos pesos das entradas. Como você deve ter notado, nesse tipo de treinamento, há a ação de um agente externo informando as saídas desejadas à rede.

Figura 2 *Aprendizado supervisionado*




Fonte: adaptado de Haykin (2001, p. 88)

Na **aprendizagem não supervisionada** (auto-organização), apenas são apresentadas à rede neural as entradas e a própria rede desenvolve habilidade

de formar representações internas para codificar as características da entrada e, desse modo, criar automaticamente novas classes. Nesse caso, não existe um agente externo nem um crítico indicando a resposta desejada para cada conjunto de entradas.

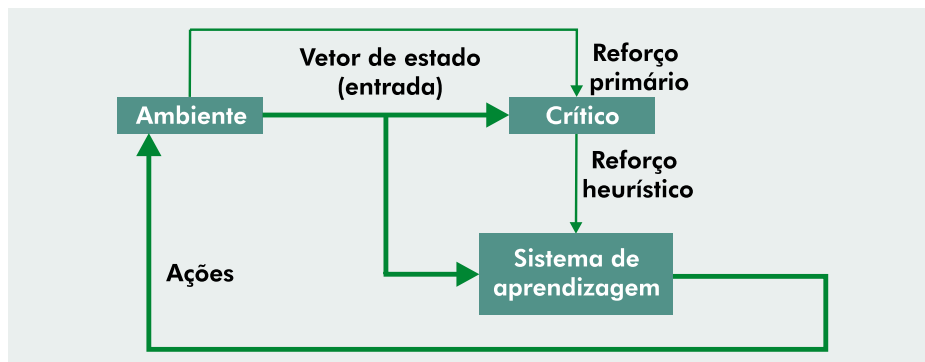
Figura 3 *Aprendizado não supervisionado*



Fonte: adaptado de Haykin (2001, p. 91)

Já na **aprendizagem por reforço**, ocorre uma combinação das duas anteriores. Ou seja, é dada, esporadicamente, mediante a intervenção de um crítico, uma avaliação global à rede da situação atual do seu treinamento.

Figura 4 *Aprendizado por reforço*



Fonte: adaptado de Haykin (2001, p. 90)

Saiba mais

No ICA (laboratório de inteligência computacional aplicada) do DEE PUC-Rio, está disponibilizado para *download* um bom material sobre redes neurais artificiais, incluindo detalhamento da etapa de treinamento, que serve para complementar o nosso estudo.

Esse material pode ser acessado no link <<http://www.ica.ele.puc-rio.br/disciplines/view.rails?idDiscipline=55&name=Redes%20Neurais%201>>.

4.3 Perceptron multicamada (*multilayer perceptron*)


Essa estrutura de RNA surgiu visando a suprir as limitações da *perceptron* clássica, com uma única camada, e foi responsável pelo ressurgimento das redes neurais artificiais após um longo período de descrédito (como visto no primeiro capítulo). Como seu próprio nome indica, trata-se de vários *perceptrons* conectados em cascata.

A dificuldade encontrada nesse tipo de RNA está justamente no seu treinamento, pois é difícil modificar corretamente os pesos da camada oculta. Pensando em resolver esse problema, de forma a permitir que um *perceptron* dessa categoria pudesse aprender, foi desenvolvido o algoritmo de **BackPropagation** (retropropagação). Como seu próprio nome indica, tem a função de propagar os erros produzidos na camada de saída de volta para as camadas anteriores para que a rede possa realizar os devidos ajustes nos pesos dos neurônios ocultos (HAYKIN, 2001).

O algoritmo de *backpropagation*, também conhecido como **regra delta generalizada**, é formulado da seguinte maneira (HAYKIN, 2001, p. 185): “O ajuste feito em um peso sináptico de um neurônio é proporcional ao produto do sinal de erro pelo sinal de entrada da sinapse em questão”.

Como pode ser visto na figura seguinte, o algoritmo ocorre sob forma de dois passos: fase *forward* (para frente) e fase *backward* (para trás).

Figura 5 Direções de dois fluxos de sinal básicos em um perceptron de multiplas camadas



Fonte: adaptado de Araujo (2005, p. 33)

No **passo para frente** (fase *forward*), os dados de entrada da rede propagam-se camada a camada até atingir a saída, sem que ocorra alteração nos pesos sinápticos da RNA. No **passo para trás** (fase *backward*), o erro calculado

na saída da rede é propagado de volta, realizando o caminho inverso ao anterior, ajustando assim os pesos sinápticos. Esse processo de ajuste dos pesos sinápticos é realizado até que a rede atinja um determinado grau de estabilidade, quando então o processo é encerrado (HAYKIN, 2001).

O *perceptron* é uma das mais importantes categorias de RNAs do tipo multicamada alimentada adiante. Segundo Araújo (2005), suas principais características são:

- cada neurônio da rede possui uma função de ativação não-linear (função logística ou sigmoide);
- a rede possui uma ou mais camadas de neurônios ocultos; e
- a rede exibe um alto grau de conectividade determinado pelas suas sinapses.

O objetivo final da etapa de treinamento é o de se obter uma rede estável com o menor índice de erro possível, mantendo sua capacidade de responder de forma satisfatória a novas variáveis de entrada (generalização).

Como vimos, as redes neurais que utilizam o algoritmo de treinamento por *backpropagation* (como muitos outros tipos de redes neurais artificiais), podem ser vistas como **caixas pretas**, nas quais praticamente não se sabe por que a rede chega a um determinado resultado, já que os modelos não apresentam justificativas para suas respostas. Outro fator que deve ser destacado nesse tipo de treinamento é a demora do processo, o qual tende a ser muito lento no caso de redes muito grandes ou com grande quantidade de dados para avaliar. Finalmente, não existem regras claras para definir a arquitetura ideal de uma RNA, podendo, para isso, serem utilizadas técnicas como os Algoritmos Genéticos, tema do nosso próximo capítulo.

Concluimos o paradigma conexionista e entraremos, a partir do próximo capítulo, no paradigma da computação evolucionária. Pode ficar tranquilo... Não falaremos mais sobre neurônios. Agora, o assunto são as teorias da evolução de Darwin aplicadas de uma forma interessante na IA. Bom proveito!

Resumo

Você viu, neste capítulo, mais um pouco sobre o paradigma conexionista e aprendeu a estrutura básica de uma rede neural artificial e as principais arquiteturas de rede existentes.

Conheceu o modelo de rede *perceptron* multicamada com aprendizado pelo algoritmo de *backpropagation* (regra delta) que, na verdade, foi o tipo de rede neural artificial que ocasionou o ressurgimento das pesquisas nessa área. Essas pesquisas estavam estagnadas há um bom tempo, pela constatação de Mynski sobre certas limitações das redes neurais artificiais de camada única.

Atividades

1. Defina, em um texto de quatro a seis linhas, o que vem a ser uma arquitetura de uma rede neural.
2. Analise atentamente as seguintes afirmativas sobre RNAs.
 - I. um parâmetro importante na hora do desenvolvimento de uma RNA é a definição de sua arquitetura, uma vez que é limitada pelo problema que terá de ser resolvido.
 - II. as redes recorrentes distinguem-se da rede neural alimentada adiante por ter ao menos um laço de realimentação.
 - III. na modalidade de aprendizagem supervisionada, são apresentadas à rede neural as entradas e a própria rede desenvolve habilidade de formar representações internas para codificar as características da entrada e, desse modo, criar automaticamente novas classes.

Podemos afirmar que

- a) apenas a afirmativa I é verdadeira.
 - b) apenas as afirmativas I e II são verdadeiras.
 - c) apenas as afirmativas II e III são verdadeiras.
 - d) todas as afirmativas são verdadeiras.
3. Redes neurais artificiais são sistemas não-lineares que imitam o mecanismo de processamento do cérebro humano e estão associadas à adaptação de conexões (sinapses) entre neurônios. Sobre redes neurais artificiais, leia as afirmativas e, em seguida, assinale a alternativa correta.
 - I. A rede neural *Perceptron* Multicamada (*Multilayer Perceptron*) surgiu visando suprir as limitações da *Perceptron* clássica, com uma única camada.
 - II. O algoritmo *backpropagation* ocorre sob a forma de dois passos: fase *backward* (os dados de entrada da rede propagam-se camada a camada até atingir a saída) e fase *forward* (o erro calculado na saída da rede é propagado de volta).
 - III. As redes neurais podem ser vistas como “caixas pretas”, nas quais praticamente não se sabe por que a rede chega a um determinado resultado, já que os modelos não apresentam justificativas para suas respostas.
 - a) Somente I é verdadeira
 - b) Somente II é verdadeira
 - c) Somente I e III são verdadeiras
 - d) Somente I e II são verdadeiras

- a) V, V, F, F c) F, F, V, V
b) F, V, F, V d) V, V, V, F

explicação dos passos estarem corretos, os nomes dos passos estão invertidos. A propagação adiante é chamada de *forward* e não *backward*, como também a propagação de volta é chamada de *backward* e não *forward* como consta na alternativa. A afirmação III é verdadeira, pois segundo o texto “é impossível saber por que uma rede chegou a uma determinada conclusão. Seus critérios decisórios são *encriptados*, não se sabendo até o momento que pesos são relevantes à tomada de uma dada decisão. Sabe-se apenas que funciona (caixa preta)”.

A resposta da **atividade 4** é a alternativa **(d)**, pois, ao contrário da quarta afirmação, cada neurônio da rede possui uma função de ativação não-linear. Assim as três primeiras afirmações estão corretas, já que o algoritmo de treinamento *backpropagation* visa à retropropagação dos erros, de forma a permitir o reajuste dos pesos das camadas internas da rede; a segunda afirmação apresenta a correta descrição da regra delta generalizada; e, o treinamento, como descrito na terceira afirmativa, visa justamente à estabilização da rede de forma a gerar respostas satisfatórias ao problema para o qual foi treinada.

Referências

ARAUJO, M. A. G. **Previsão de Demanda de Energia Elétrica por Meio de Redes Neurais Artificiais**. Dissertação (Mestrado) – Universidade Federal do Rio Grande do Sul, Escola de Administração. Programa de Pós-graduação em Administração, Porto Alegre, 2005.

BITTENCOURT, Guilherme. **Inteligência Computacional**. Universidade Federal de Santa Catarina – UFSC. Disponível em: <<http://www.das.ufsc.br/gia/softcomp/softcomp.html>>. Acesso em: 15 fev. 2008.

HAYKIN, Simon. **Redes Neurais**: princípios e prática. Porto Alegre: Bookman, 2001.

Anotações

[illegible]

[illegible]