

Representação do Conhecimento em IA

Fundamentos e Aplicações no Contexto do Supermercado BuonoPreço

A representação do conhecimento é um dos pilares históricos da Inteligência Artificial (IA), especialmente nas abordagens **simbólicas**, também conhecidas como **IA baseada em conhecimento** ou **Good Old-Fashioned AI (GoFAI)**. Conforme destacam *Russell e Norvig (2021)*, o sucesso de um agente inteligente depende de sua capacidade de **representar o mundo de maneira precisa, organizada e manipulável**, de modo que possa **raciocinar, tomar decisões e aprender com base nesse conhecimento** — mesmo que tal “aprendizado” ocorra por inserção manual e não por inferência estatística.

Embora o paradigma simbólico tenha perdido protagonismo com o avanço do **aprendizado de máquina** e das **redes neurais profundas**, ele permanece essencial para a compreensão das **bases conceituais da IA**, sendo ainda utilizado em aplicações onde a **transparência, a lógica e a interpretabilidade** são requisitos centrais — como sistemas especialistas, ontologias formais e módulos explicativos de IA híbrida.

1. O que é Representação do Conhecimento?

No contexto da IA, representar conhecimento significa **estruturar informações sobre o mundo real** (fatos, regras, conceitos, relações, eventos) em um formato que possa ser **armazenado, interpretado e manipulado por algoritmos**. É o processo que transforma **informações informais e subjetivas** — por exemplo, “clientes gostam de produtos frescos” — em **estruturas formais**, como tabelas, regras lógicas ou grafos, que permitem inferências computacionais.

De forma sintética, representação do conhecimento envolve três aspectos principais:

- **Modelagem formal da realidade:** usando estruturas bem definidas.
- **Capacidade de inferência:** permitindo gerar novos conhecimentos a partir dos existentes.
- **Eficiência computacional:** viabilizando operações em tempo útil.

2. Tipos Comuns de Representação (no Paradigma Simbólico)

Segundo *Russell e Norvig (2021)*, os principais esquemas de representação simbólica incluem:

- **Tabelas e bases de dados relacionais:** úteis para armazenar fatos estruturados.

Exemplo no BuonoPreço: uma tabela com colunas `cliente_id`, `produto`, `data_compra`.

- **Regras de produção (se-então):** usadas para expressar inferências simples e regras de decisão.

Exemplo: “Se cliente compra leite frequentemente, então sugerir pão”.

- **Redes semânticas e grafos conceituais:** representam conceitos e relações em estruturas conectadas.

Exemplo: “leite” é um tipo de “produto”; “produto” tem “categoria”.

- **Frames e ontologias leves:** organizam conhecimento em estruturas hierárquicas com propriedades.

Exemplo: um frame “Produto” com propriedades como preço, estoque, validade.

- **Lógicas formais (proposicional, de predicados):** mais comuns em sistemas especialistas e agentes lógicos.

Exemplo: $\text{Compra}(\text{joao}, \text{leite}) \wedge \text{Frequente}(\text{joao}) \rightarrow \text{Sugerir}(\text{joao}, \text{pao})$

Essas estruturas variam em expressividade e complexidade, e a escolha adequada depende da natureza do problema e do tipo de raciocínio desejado.

3. Representação Implícita no Paradigma Conexionista

Enquanto a IA simbólica utiliza estruturas explícitas e manipuláveis, o paradigma conexionista — baseado em redes neurais — **representa conhecimento de forma implícita**. Em redes neurais artificiais, o conhecimento é codificado nas **conexões e pesos ajustados durante o treinamento**, sendo **distribuído e não interpretável diretamente**. Isso dificulta a análise sem ferramentas específicas, mas oferece maior capacidade de generalização e adaptação a dados complexos.

Como destaca Haykin (2007, p. 49–50), **um sistema de IA não aprende nem raciocina sobre dados brutos — ele aprende sobre representações**. No paradigma conexionista, essas representações são extraídas automaticamente, sem necessidade de um engenheiro do conhecimento.

Essa ideia é reforçada por LeCun, Bengio e Hinton (2015), ao afirmarem que o deep learning permite que sistemas computacionais aprendam **representações de dados com múltiplos níveis de abstração**, eliminando a necessidade de engenharia manual de características. As representações latentes aprendidas por redes profundas capturam padrões relevantes para tarefas como reconhecimento de imagens, análise de sentimentos e tomada de decisão, de forma **hierárquica, distribuída e autoajustada**. Como os autores sintetizam:

“Deep learning allows computational models that are composed of multiple processing layers to learn representations of data with multiple levels of abstraction.”
(LECUN; BENGIO; HINTON, 2015, p. 436)

Essa capacidade de construir representações diretamente a partir dos dados brutos representa uma ruptura metodológica em relação aos modelos simbólicos, destacando a natureza implícita e adaptativa da representação no paradigma conexionista.

Portanto, ao abordar representação de conhecimento, é importante reconhecer que ela **assume formas diferentes nos diversos paradigmas de IA: explícita** e estruturada no simbólico; **implícita e distribuída** no conexionista; e **estocástica** no paradigma probabilístico (como nas redes bayesianas).

4. Aplicações Práticas no BuonoPreço

No caso do BuonoPreço, diversos conhecimentos tácitos e informais podem ser formalizados para aplicação futura de IA. Veja alguns exemplos:

<i>Conhecimento Tácito</i>	<i>Representação Formal (Simbólica)</i>	<i>Possível Uso com IA</i>
“Sexta-feira é dia de muita venda de carne”	Tabela com dia_semana, categoria, volume_venda	Previsão de demanda com séries temporais (LSTM)
“Clientes que compram queijo coalho gostam de tapioca”	Regra Se produto = queijo_coalho → sugerir = tapioca	Recomendação personalizada
“Alguns bairros têm entrega mais demorada”	Grafo de locais com tempo médio de entrega	Otimização de rotas com algoritmos genéticos
“Promoções surtiram mais efeito no fim do mês”	Tabela com data, tipo_promocao, venda_total	Análise de impacto e segmentação

Ao transformar esses saberes em representações explícitas ou estruturadas, torna-se possível aplicar algoritmos de IA com **coerência, eficiência e propósito**, inclusive em sistemas híbridos que combinam representação simbólica com técnicas de aprendizado.

5. Considerações Finais

Em resumo, a representação do conhecimento é **a base conceitual de qualquer sistema inteligente**, seja na forma explícita de regras e fatos ou na forma implícita de parâmetros numéricos. Ao longo da disciplina, devemos compreender que **a eficácia de um sistema de IA depende tanto da qualidade da representação quanto da técnica empregada**, e que **diferentes paradigmas tratam esse problema de modos distintos**.

Com esse entendimento, é possível aplicar eficientemente algoritmos ao **projetar soluções de IA mais adequadas à realidade e aos objetivos do problema a ser resolvido**.

Referências

NORVIG, Peter; RUSSEL, Stuart; VIEIRA. Inteligência Artificial. *Rio de Janeiro, RJ*, 2022.

HAYKIN, Simon. Redes neurais: Princípios e prática. 2 ed. *Porto Alegre*, 2007.

LECUN, Yann; BENGIO, Yoshua; HINTON, Geoffrey. Deep learning. *Nature*, v. 521, n. 7553, p. 436–444, 2015. DOI: [10.1038/nature14539](https://doi.org/10.1038/nature14539).